Análisis Correlacional y Significancia Estadística

Tarea 4.1.2 · SciPy Stats (Spearman, Pearson, Kruskal-Wallis, Bootstrap)

Analisis Correlacional y de Significancia Estadistica

Modulo: NetDiagBench-L7 / Layer 7 - Statistical Analysis

Muestras totales: 162 corridas, 3 modelos evaluados

1. Correlacion Parametros del Modelo vs Metricas de Rendimiento

Analisis de la relacion entre el numero de parametros del modelo (eje X)

y cada metrica de rendimiento (eje Y), usando correlacion de Spearman (rho)

y Pearson (r) con su p-value asociado.

Metrica	Spearman rho	p-value	Pearson r	p-value	Significativo (p<0.05)
TTFT (ms)	0.8306	p < 0.001	0.7761	p < 0.001	Si
Tokens/s	-0.5884	p < 0.001	-0.2707	p < 0.001	Si
Latencia Total (ms)	0.7661	p < 0.001	0.8001	p < 0.001	Si
Energia (kWh)	0.7816	p < 0.001	0.8128	p < 0.001	Si
Rubrica (0-5)	0.2864	p < 0.001	0.3113	p < 0.001	Si
Puntaje de Coincidencia Parcial	0.3546	p < 0.001	0.4089	p < 0.001	Si

2. Prueba de Kruskal-Wallis: Diferencias entre Modelos

H0: Las distribuciones de la metrica son identicas entre los k modelos.

Se rechaza H0 si p < 0.05.

Metrica	H Estadistico	p-value	Diferencias Significativas
TTFT (ms)	115.9343	p < 0.001	Si
Tokens/s	58.0983	p < 0.001	Si
Latencia Total (ms)	109.5798	p < 0.001	Si
Energia (kWh)	110.9144	p < 0.001	Si
Rubrica (0-5)	15.3527	p < 0.001	Si
Puntaje de Coincidencia Parcial	26.2864	p < 0.001	Si

3. Intervalos de Confianza Bootstrap al 95%

Modelo	Metrica	IC 95% Inferior	IC 95% Superior
glm-4-9b-chat	TTFT (ms)	173733.825	193533.5359
glm-4-9b-chat	Tokens/s	3.2819	3.4226
glm-4-9b-chat	Latencia (ms)	383535.7183	427132.5596
glm-4-9b-chat	Energia (kWh)	0.0159	0.018
phi-4-mini-instruct	TTFT (ms)	76912.9794	89507.4619
phi-4-mini-instruct	Tokens/s	4.292	6.538
phi-4-mini-instruct	Latencia (ms)	161787.5457	186661.4344
phi-4-mini-instruct	Energia (kWh)	0.0056	0.0065
qwen3-8b	TTFT (ms)	151745.6528	173262.8374
qwen3-8b	Tokens/s	3.3343	3.6367
qwen3-8b	Latencia (ms)	363856.3128	417268.8717
qwen3-8b	Energia (kWh)	0.0149	0.0173

4. Tamano del Efecto (d de Cohen) entre Pares de Modelos

Metrica	Comparacion	d de Cohen	Interpretacion
TTFT (ms)	glm-4-9b-chat vs phi-4-mini-instruct	3.1227	Efecto grande (Large)
TTFT (ms)	glm-4-9b-chat vs qwen3-8b	0.5406	Efecto mediano (Medium)
TTFT (ms)	phi-4-mini-instruct vs qwen3-8b	-2.3692	Efecto grande (Large)
Tokens/s	glm-4-9b-chat vs phi-4-mini-instruct	-0.5054	Efecto mediano (Medium)
Tokens/s	glm-4-9b-chat vs qwen3-8b	-0.2908	Efecto pequeno (Small)
Tokens/s	phi-4-mini-instruct vs qwen3-8b	0.4647	Efecto pequeno (Small)
Latencia Total (ms)	glm-4-9b-chat vs phi-4-mini-instruct	3.438	Efecto grande (Large)
Latencia Total (ms)	glm-4-9b-chat vs qwen3-8b	0.167	Efecto insignificante (Negligible)
Latencia Total (ms)	phi-4-mini-instruct vs qwen3-8b	-2.8173	Efecto grande (Large)

5. Estadisticos Descriptivos Consolidados por Modelo

Modelo	Metrica	Media	Sigma	CV%	p50	p95	N
glm-4-9b-chat	TTFT (ms)	182835.9909	38502.7137	21.06	169766.42	279890.69	54
glm-4-9b-chat	Tokens/s	3.3576	0.2689	8.01	3.48	3.56	54
glm-4-9b-chat	Latencia (ms)	403622.2928	83070.8367	20.58	379153.58	609063.12	54
glm-4-9b-chat	VRAM (Declarada/Estimada) Pico (GB)	5.9	0.0	0.0	5.9	5.9	54
glm-4-9b-chat	RAM Pico (MB)	392.1669	159.6219	40.7	420.77	581.06	54
glm-4-9b-chat	Energia (kWh)	0.0169	0.0039	22.91	0.0159	0.0265	54
glm-4-9b-chat	Rubrica (0-5)	4.1296	0.8079	19.56	4.0	5.0	54
glm-4-9b-chat	Puntaje de Coincidencia Parcial	0.7615	0.2076	27.26	0.8	1.0	54
phi-4-mini-instruct	TTFT (ms)	83215.3641	23517.1987	28.26	77004.29	128316.29	54
phi-4-mini-instruct	Tokens/s	5.108	4.8907	95.75	4.77	5.12	54
phi-4-mini-instruct	Latencia (ms)	174412.4165	44599.089	25.57	173283.46	264736.02	54
phi-4-mini-instruct	VRAM (Declarada/Estimada) Pico (GB)	2.8407	0.2994	10.54	2.8	2.8	54
phi-4-mini-instruct	RAM Pico (MB)	223.6072	108.0076	48.3	223.19	389.18	54
phi-4-mini-instruct	Energia (kWh)	0.006	0.0017	27.71	0.0058	0.0096	54
phi-4-mini-instruct	Rubrica (0-5)	3.5463	0.8969	25.29	4.0	5.0	54
phi-4-mini-instruct	Puntaje de Coincidencia Parcial	0.4957	0.3334	67.26	0.6176	0.9608	54
qwen3-8b	TTFT (ms)	161507.9446	40385.8496	25.01	143054.61	249486.27	54
qwen3-8b	Tokens/s	3.4896	0.583	16.71	3.82	4.02	54
qwen3-8b	Latencia (ms)	388469.5481	97756.8374	25.16	353103.49	637374.21	54
qwen3-8b	VRAM (Declarada/Estimada) Pico (GB)	5.5	0.0	0.0	5.5	5.5	54
qwen3-8b	RAM Pico (MB)	157.6437	40.1918	25.5	145.91	240.34	54
qwen3-8b	Energia (kWh)	0.016	0.0044	27.65	0.0144	0.0272	54
qwen3-8b	Rubrica (0-5)	4.0741	0.7098	17.42	4.0	5.0	54
qwen3-8b	Puntaje de Coincidencia Parcial	0.736	0.2513	34.15	0.8	1.0	54

6. Métricas de Clasificación Diagnóstica y F1 Macro (Tarea 4.1.3)

Modelo	F1 Macro	IC 95% Bootstrap F1	Precisión Macro	Recall Macro
glm-4-9b-chat	0.8832	[0.7092, 0.9333]	0.9130	0.8889
phi-4-mini-instruct	0.5529	[0.4033, 0.6100]	0.5741	0.5926
qwen3-8b	0.8302	[0.6741, 0.8806]	0.8444	0.8519

7. Interpretacion y Conclusiones (Tarea 4.1.2 / OE4)

Se encontraron correlaciones estadisticamente significativas ($p < 0.05$) entre el numero de parametros del modelo y las siguientes metricas: **TTFT (ms), Tokens/s, Latencia Total (ms), Energia (kWh), Rubrica (0-5), Puntaje de Coincidencia Parcial**.

La prueba de Kruskal-Wallis revela diferencias estadisticamente significativas entre modelos en: **TTFT (ms), Tokens/s, Latencia Total (ms), Energia (kWh), Rubrica (0-5), Puntaje de Coincidencia Parcial** ($p < 0.05$), lo que confirma que la eleccion del modelo tiene un impacto medible en el rendimiento.

Reporte autogenerado por NetDiagBench-L7 Statistical Analysis Module.