Informe Técnico Comparativo (OE4)

Matriz Multidimensional y Análisis de Compensación (Trade-Offs)

Informe T■®cnico Comparativo: NetDiagBench-L7

Fecha de Generaci■■n: 2026-11-12 00:47:43

Huella de Hardware: `OS=Windows_11; CPU=AMD64 Family 23 Model 160 Stepping 0, AuthenticAMD; Cores=8; RAM=13.8GB; VRAM_Limit=8.0GB`

Total de Pruebas Incluidas: 162

Modelos Incluidos en el Informe: glm-4-9b-chat, phi-4-mini-instruct, qwen3-8b

1. Matriz de Evaluaci■■n Multidimensional (OE4 / Tarea 4.2.2)

Modelo	Precisi■■n Diagn■■stica	Puntaje de Coincidencia Parcial	Tasa Evidencia	TTFT Prom.	Vel. Tok/s	Latencia p50	Latencia p95	VRAM (Declarada/Estimada) Pico	R■■brica (0-5)
glm-4-9b-chat	74.1%	0.607	42.6%	288148.8 ms	2.9 tok/s	501916.8 ms	706684.8 ms	5.9 GB	4.13 / 5.0
phi-4-mini-instruct	64.8%	0.36	0.0%	133724.2 ms	3.3 tok/s	213264.3 ms	248464.1 ms	2.8 GB	3.55 / 5.0
qwen3-8b	87.0%	0.543	27.8%	253500.1 ms	1.8 tok/s	761328.4 ms	1681855.0 ms	5.5 GB	4.07 / 5.0

2. Desglose de Precisi■■n por Escenario y Modelo

Escenario	glm-4-9b-chat	phi-4-mini-instruct	qwen3-8b
DNS-DEL-01	[OK] 100%	[!] 33%	[OK] 100%
DNS-NXD-01	[OK] 100%	[OK] 100%	[!] 0%
DNS-REF-01	[OK] 100%	[OK] 100%	[!] 67%
DNS-SRV-01	[!] 0%	[!] 0%	[OK] 100%
DNS-TRUNC-01	[OK] 100%	[!] 33%	[!] 0%
HTTP-403-01	[OK] 100%	[!] 0%	[OK] 100%
HTTP-429-01	[!] 33%	[!] 0%	[OK] 100%
HTTP-500-01	[OK] 100%	[!] 33%	[!] 0%
HTTP-502-01	[!] 0%	[!] 0%	[!] 33%
HTTP-503-01	[!] 33%	[!] 0%	[!] 0%
HTTP-504-01	[!] 67%	[!] 0%	[!] 0%
HTTP-ORIGIN-01	[!] 33%	[!] 0%	[!] 33%
HTTP-POOL-01	[!] 67%	[!] 0%	[!] 0%
NET-LAT-01	[!] 0%	[!] 0%	[!] 33%
TLS-CHN-01	[!] 67%	[!] 0%	[!] 67%
TLS-CIPH-01	[OK] 100%	[!] 67%	[OK] 100%
TLS-EXP-01	[!] 0%	[!] 0%	[!] 0%
TLS-SNI-01	[OK] 100%	[OK] 100%	[!] 67%

3. Estimaci■■n de Huella Energ■®tica y Carbono (Tarea 4.2.2c)

Modelo	Energ■¡a Total (kWh)	CO2 Estimado (kg)	Eficiencia Tok/Wh
glm-4-9b-chat	1.131579 kWh	0.316842 kg	71533.5 tok/Wh
phi-4-mini-instruct	0.459677 kWh	0.128710 kg	80975.5 tok/Wh
qwen3-8b	2.033261 kWh	0.569313 kg	42540.5 tok/Wh

4. An■ílisis de Compromiso y Configuraci■■n Recomendada (Tarea 4.3.1)

Comparaci■■n de Compensaciones (Trade-Offs):

- **glm-4-9b-chat (9.0B):** Precision 74.1%, TTFT 288148.8 ms, 2.9 tok/s, VRAM 5.9 GB, Rubrica 4.13/5.0. Score de Eficiencia: **0.7323**.

Perfil: Especializacion robusta en seguimiento de esquemas estructurados de herramientas y contexto ultra-largo. Registra 74.1% de exactitud diagnostica completa (40/54), 61.1% estricta (33/54), 4.13/5.0 en rubrica humana historica y puntaje compuesto provisional de 0.7323 (ELEGIBLE).

- **qwen3-8b (8.2B):** Precision 87.0%, TTFT 253500.1 ms, 1.8 tok/s, VRAM 5.5 GB, Rubrica 4.07/5.0. Score de Eficiencia: **0.7217**.

Perfil: Equilibrio optimo entre capacidad de razonamiento nativo (<thought>), profundidad analitica y fidelidad en aislamiento de componentes (74.1%). calidad explicativa (4.07/5.0). Registra 87.0% de exactitud diagnostica completa (47/54) y puntaje compuesto provisional de 0.7217 (ELEGIBLE). Opera con margen holgado en GPUs de 8 GB VRAM (5.5

GB).

- **phi-4-mini-instruct (3.8B):** Precision 64.8%, TTFT 133724.2 ms, 3.3 tok/s, VRAM 2.8 GB, Rubrica 3.55/5.0. Score de Eficiencia: **0.8012**.

Perfil: Maxima eficiencia computacional y minima huella de memoria (2.8 GB declarados, TTFT de 133.7 s, 3.3 tok/s, 0.460 kWh). Exactitud del 64.8% completa (35/54, sub-umbral autonomo del 70.0%) y puntaje compuesto provisional de 0.8012 (NO ELEGIBLE por umbral autonomo).

5. Desglose de Resultados por Modo de Ejecuci■■n (135 Simuladas vs. 27 Emuladas)

Modo de Ejecuci■■n	Total Corridas	Precisi■■n Diagn■■stica	Tasa Evidencia	Latencia Media (ms)	R■■brica Prom.
Laboratorio en Contenedores (Docker Compose) (emulado)	27	14.8%	22.2%	665644.3 ms	3.78 / 5.0
Simulador Sint■®tico Calibrado (sintetico _determinista)	135	49.6%	23.7%	528914.5 ms	3.94 / 5.0

Conclusion de Seleccion (OE4 / Tarea 4.3.1): 1. **Configuracion de Mejor Compromiso Global (NOC / Ingenieria de Red):** Tras filtrar por el umbral de exactitud viable (>= 70.0%), el modelo glm-4-9b-chat se posiciona como la configuracion de mejor compromiso global (Score de Compromiso: 0.732), alcanzando la maxima precision diagnostica (74.1%), 2.9 tok/s y una rubrica explicativa de 4.13/5.0 (VRAM declarada: 5.9 GB). 2. **Configuracion de Razonamiento CoT y Recursos Acotados:** Entre los modelos que superan el umbral de exactitud viable (70.0%), qwen3-8b presenta la menor huella computacional con 5.5 GB de VRAM (Declarada/Estimada), el mayor aislamiento de componentes (59.3%) y la mas alta calidad explicativa (rubrica 4.07/5.0 con 87.0% de precision), configurandose como la opcion recomendada para despliegues con recursos de GPU acotados (8 GB). 3. **Evaluacion para Despliegues de Borde y Triaje Preliminar (Edge Computing):** El modelo phi-4-mini-instruct ofrece la mayor velocidad (3.3 tok/s, TTFT de 133724.2 ms) y la menor huella fisica (2.8 GB VRAM, 0.460 kWh). No obstante, al obtener 64.8% de precision (por debajo del umbral del 70.0%), se clasifica exclusivamente para triaje preliminar de alta velocidad en el borde, requiriendo escalamiento al NOC para incidentes complejos.

Reporte autogenerado por NetDiagBench-L7 (selecci■■n de modelos del usuario).