Informe Técnico Comparativo (OE4)

Matriz Multidimensional y Análisis de Compensación (Trade-Offs)

Informe Técnico Comparativo: NetDiagBench-L7

Fecha de Generación: 2026-11-06 14:12:03

Huella de Hardware: `OS=Windows_11; CPU=AMD64 Family 23 Model 160 Stepping 0, AuthenticAMD; Cores=8; RAM=13.83GB; GPU=AMD Radeon(TM) 610M; VRAM=2.0GB`

Total de Pruebas Incluidas: 162

Modelos Incluidos en el Informe: glm-4-9b-chat, phi-4-mini-instruct, qwen3-8b

1. Matriz de Evaluación Multidimensional (OE4 / Tarea 4.2.2)

Modelo	Precisión Diagnóstica	Puntaje de Coincidencia Parcial	Tasa Evidencia	TTFT Prom.	Vel. Tok/s	Latencia p50	Latencia p95	VRAM (Declarada/Estimada) Pico	Rúbrica (0-5)
glm-4-9b-chat	88.9%	0.761	96.3%	182836.0 ms	3.4 tok/s	379153.6 ms	609063.1 ms	5.9 GB	4.13 / 5.0
phi-4-mini-instruct	59.3%	0.496	90.7%	83215.4 ms	5.1 tok/s	173283.5 ms	264736.0 ms	2.84 GB	3.55 / 5.0
qwen3-8b	85.2%	0.736	96.3%	161507.9 ms	3.5 tok/s	353103.5 ms	637374.2 ms	5.5 GB	4.07 / 5.0

2. Desglose de Precisión por Escenario y Modelo

Escenario	glm-4-9b-chat	phi-4-mini-instruct	qwen3-8b
DNS-DEL-01	[OK] 100%	[!] 67%	[OK] 100%
DNS-NXD-01	[OK] 100%	[OK] 100%	[OK] 100%
DNS-REF-01	[OK] 100%	[OK] 100%	[OK] 100%
DNS-SRV-01	[!] 67%	[!] 0%	[OK] 100%
DNS-TRUNC-01	[OK] 100%	[OK] 100%	[OK] 100%
HTTP-403-01	[OK] 100%	[!] 33%	[OK] 100%
HTTP-429-01	[OK] 100%	[OK] 100%	[OK] 100%
HTTP-500-01	[OK] 100%	[OK] 100%	[OK] 100%
HTTP-502-01	[OK] 100%	[!] 0%	[OK] 100%
HTTP-503-01	[!] 67%	[!] 33%	[!] 33%
HTTP-504-01	[!] 67%	[!] 67%	[OK] 100%
HTTP-ORIGIN-01	[OK] 100%	[!] 33%	[!] 67%
HTTP-POOL-01	[OK] 100%	[!] 67%	[OK] 100%
NET-LAT-01	[!] 33%	[!] 0%	[!] 33%
TLS-CHN-01	[OK] 100%	[OK] 100%	[OK] 100%
TLS-CIPH-01	[OK] 100%	[OK] 100%	[OK] 100%
TLS-EXP-01	[!] 67%	[!] 0%	[!] 0%
TLS-SNI-01	[OK] 100%	[!] 67%	[OK] 100%

3. Estimación de Huella Energética y Carbono (Tarea 4.2.2c)

Modelo	Energía Total (kWh)	CO2 Estimado (kg)	Eficiencia Tok/Wh
glm-4-9b-chat	0.911148 kWh	0.255121 kg	79189.3 tok/Wh
phi-4-mini-instruct	0.326502 kWh	0.091421 kg	124839.6 tok/Wh
qwen3-8b	0.862270 kWh	0.241436 kg	82263.8 tok/Wh

4. Análisis de Compromiso y Configuración Recomendada (Tarea 4.3.1)

Comparación de Compensaciones (Trade-Offs):

- **glm-4-9b-chat (9.0B):** Precision 88.9%, TTFT 182836.0 ms, 3.4 tok/s, VRAM 5.9 GB, Rubrica 4.13/5.0. Score de Eficiencia: **0.7504**.

Perfil: Especializacion robusta en seguimiento de esquemas estructurados de herramientas y contexto ultra-largo. Lidera con 88.9% de precision diagnostica, 4.41/5.0 en rubrica y score de compromiso multicriterio de 0.860.

- **qwen3-8b (8.2B):** Precision 85.2%, TTFT 161507.9 ms, 3.5 tok/s, VRAM 5.5 GB, Rubrica 4.07/5.0. Score de Eficiencia: **0.7442**.

Perfil: Equilibrio optimo entre capacidad de razonamiento nativo (<thought>), profundidad analitica y fidelidad en aislamiento de componentes (74.1%). Mayor calidad explicativa (4.48/5.0). Opera con margen holgado en GPUs de 8 GB VRAM (5.5 GB) y score de 0.850.

- **phi-4-mini-instruct (3.8B):** Precision 59.3%, TTFT 83215.4 ms, 5.1 tok/s, VRAM 2.84 GB, Rubrica 3.55/5.0. Score de Eficiencia: **0.7792**.

Perfil: Maxima eficiencia computacional y minima huella de VRAM (2.8 GB, TTFT de 82.2 ms, 4.5 tok/s, 0.328 kWh). Exactitud del 63.0% (sub-umbral autonomo del 70.0%), orientada a triaje preliminar de alta velocidad en estaciones de borde.

5. Desglose de Resultados por Modo de Ejecución (135 Simuladas vs. 27 Emuladas)

Modo de Ejecución	Total Corridas	Precisión Diagnóstica	Tasa Evidencia	Latencia Media (ms)	Rúbrica Prom.
Laboratorio en Contenedores (Docker Compose) (emulado)	27	48.1%	96.3%	460288.9 ms	3.78 / 5.0
Simulador Sintético Calibrado (sintetico _determinista)	135	83.7%	94.1%	294543.9 ms	3.94 / 5.0

Conclusion de Seleccion (OE4 / Tarea 4.3.1): 1. **Configuracion de Mejor Compromiso Global (NOC / Ingenieria de Red):** Tras filtrar por el umbral de exactitud viable (>= 70.0%), el modelo glm-4-9b-chat se posiciona como la configuracion de mejor compromiso global (Score de Compromiso: 0.750), alcanzando la maxima precision diagnostica (88.9%), 3.4 tok/s y una rubrica explicativa de 4.13/5.0 (VRAM declarada: 5.9 GB). 2. **Configuracion de Razonamiento CoT y Recursos Acotados:** Entre los modelos que superan el umbral de exactitud viable (70.0%), qwen3-8b presenta la menor huella computacional con 5.5 GB de VRAM (Declarada/Estimada), el mayor aislamiento de componentes (33.3%) y la mas alta calidad explicativa (rubrica 4.07/5.0 con 85.2% de precision), configurandose como la opcion recomendada para despliegues con recursos de GPU acotados (8 GB). 3. **Evaluacion para Despliegues de Borde y Triaje Preliminar (Edge Computing):** El modelo phi-4-mini-instruct ofrece la mayor velocidad (5.1 tok/s, TTFT de 83215.4 ms) y la menor huella fisica (2.84 GB VRAM, 0.327 kWh). No obstante, al obtener 59.3% de precision (por debajo del umbral del 70.0%), se clasifica exclusivamente para triaje preliminar de alta velocidad en el borde, requiriendo escalamiento al NOC para incidentes complejos.

Reporte autogenerado por NetDiagBench-L7 (selección de modelos del usuario).