NetDiagBench-L7: Informe Técnico Consolidado

Universidad de Pamplona · Evaluación Integral de Modelos SLM para Diagnóstico L7

Informe T■®cnico Comparativo: NetDiagBench-L7

Fecha de Generaci■■n: 2026-11-12 00:47:56

Huella de Hardware: `OS=Windows_11; CPU=AMD64 Family 23 Model 160 Stepping 0, AuthenticAMD; Cores=8; RAM=13.8GB; VRAM_Limit=8.0GB`

Total de Pruebas Incluidas: 162

Modelos Incluidos en el Informe: glm-4-9b-chat, phi-4-mini-instruct, qwen3-8b

1. Matriz de Evaluaci■■n Multidimensional (OE4 / Tarea 4.2.2)

Modelo	Precisi■■n Diagn■■stica	Puntaje de Coincidencia Parcial	Tasa Evidencia	TTFT Prom.	Vel. Tok/s	Latencia p50	Latencia p95	VRAM (Declarada/Estimada) Pico	R■■brica (0-5)
glm-4-9b-chat	74.1%	0.607	42.6%	288148.8 ms	2.9 tok/s	501916.8 ms	706684.8 ms	5.9 GB	4.13 / 5.0
phi-4-mini-instruct	64.8%	0.36	0.0%	133724.2 ms	3.3 tok/s	213264.3 ms	248464.1 ms	2.8 GB	3.55 / 5.0
qwen3-8b	87.0%	0.543	27.8%	253500.1 ms	1.8 tok/s	761328.4 ms	1681855.0 ms	5.5 GB	4.07 / 5.0

2. Desglose de Precisi■■n por Escenario y Modelo

Escenario	glm-4-9b-chat	phi-4-mini-instruct	qwen3-8b
DNS-DEL-01	[OK] 100%	[!] 33%	[OK] 100%
DNS-NXD-01	[OK] 100%	[OK] 100%	[!] 0%
DNS-REF-01	[OK] 100%	[OK] 100%	[!] 67%
DNS-SRV-01	[!] 0%	[!] 0%	[OK] 100%
DNS-TRUNC-01	[OK] 100%	[!] 33%	[!] 0%
HTTP-403-01	[OK] 100%	[!] 0%	[OK] 100%
HTTP-429-01	[!] 33%	[!] 0%	[OK] 100%
HTTP-500-01	[OK] 100%	[!] 33%	[!] 0%
HTTP-502-01	[!] 0%	[!] 0%	[!] 33%
HTTP-503-01	[!] 33%	[!] 0%	[!] 0%
HTTP-504-01	[!] 67%	[!] 0%	[!] 0%
HTTP-ORIGIN-01	[!] 33%	[!] 0%	[!] 33%
HTTP-POOL-01	[!] 67%	[!] 0%	[!] 0%
NET-LAT-01	[!] 0%	[!] 0%	[!] 33%
TLS-CHN-01	[!] 67%	[!] 0%	[!] 67%
TLS-CIPH-01	[OK] 100%	[!] 67%	[OK] 100%
TLS-EXP-01	[!] 0%	[!] 0%	[!] 0%
TLS-SNI-01	[OK] 100%	[OK] 100%	[!] 67%

3. Estimaci■■n de Huella Energ■®tica y Carbono (Tarea 4.2.2c)

Modelo	Energ■¡a Total (kWh)	CO2 Estimado (kg)	Eficiencia Tok/Wh
glm-4-9b-chat	1.131579 kWh	0.316842 kg	71533.5 tok/Wh
phi-4-mini-instruct	0.459677 kWh	0.128710 kg	80975.5 tok/Wh
qwen3-8b	2.033261 kWh	0.569313 kg	42540.5 tok/Wh

4. An■ílisis de Compromiso y Configuraci■■n Recomendada (Tarea 4.3.1)

Comparaci■■n de Compensaciones (Trade-Offs):

- **glm-4-9b-chat (9.0B):** Precision 74.1%, TTFT 288148.8 ms, 2.9 tok/s, VRAM 5.9 GB, Rubrica 4.13/5.0. Score de Eficiencia: **0.7323**.

Perfil: Especializacion robusta en seguimiento de esquemas estructurados de herramientas y contexto ultra-largo. Registra 74.1% de exactitud diagnostica completa (40/54), 61.1% estricta (33/54), 4.13/5.0 en rubrica humana historica y puntaje compuesto provisional de 0.7323 (ELEGIBLE).

- **qwen3-8b (8.2B):** Precision 87.0%, TTFT 253500.1 ms, 1.8 tok/s, VRAM 5.5 GB, Rubrica 4.07/5.0. Score de Eficiencia: **0.7217**.

Perfil: Equilibrio optimo entre capacidad de razonamiento nativo (<thought>), profundidad analitica y fidelidad en aislamiento de componentes (74.1%). calidad explicativa (4.07/5.0). Registra 87.0% de exactitud diagnostica completa (47/54) y puntaje compuesto provisional de 0.7217 (ELEGIBLE). Opera con margen holgado en GPUs de 8 GB VRAM (5.5

GB).

- **phi-4-mini-instruct (3.8B):** Precision 64.8%, TTFT 133724.2 ms, 3.3 tok/s, VRAM 2.8 GB, Rubrica 3.55/5.0. Score de Eficiencia: **0.8012**.

Perfil: Maxima eficiencia computacional y minima huella de memoria (2.8 GB declarados, TTFT de 133.7 s, 3.3 tok/s, 0.460 kWh). Exactitud del 64.8% completa (35/54, sub-umbral autonomo del 70.0%) y puntaje compuesto provisional de 0.8012 (NO ELEGIBLE por umbral autonomo).

5. Desglose de Resultados por Modo de Ejecuci■■n (135 Simuladas vs. 27 Emuladas)

Modo de Ejecuci■■n	Total Corridas	Precisi■■n Diagn■■stica	Tasa Evidencia	Latencia Media (ms)	R■■brica Prom.
Laboratorio en Contenedores (Docker Compose) (emulado)	27	14.8%	22.2%	665644.3 ms	3.78 / 5.0
Simulador Sint■®tico Calibrado (sintetico _determinista)	135	49.6%	23.7%	528914.5 ms	3.94 / 5.0

Conclusion de Seleccion (OE4 / Tarea 4.3.1): 1. **Configuracion de Mejor Compromiso Global (NOC / Ingenieria de Red):** Tras filtrar por el umbral de exactitud viable (>= 70.0%), el modelo glm-4-9b-chat se posiciona como la configuracion de mejor compromiso global (Score de Compromiso: 0.732), alcanzando la maxima precision diagnostica (74.1%), 2.9 tok/s y una rubrica explicativa de 4.13/5.0 (VRAM declarada: 5.9 GB). 2. **Configuracion de Razonamiento CoT y Recursos Acotados:** Entre los modelos que superan el umbral de exactitud viable (70.0%), qwen3-8b presenta la menor huella computacional con 5.5 GB de VRAM (Declarada/Estimada), el mayor aislamiento de componentes (59.3%) y la mas alta calidad explicativa (rubrica 4.07/5.0 con 87.0% de precision), configurandose como la opcion recomendada para despliegues con recursos de GPU acotados (8 GB). 3. **Evaluacion para Despliegues de Borde y Triaje Preliminar (Edge Computing):** El modelo phi-4-mini-instruct ofrece la mayor velocidad (3.3 tok/s, TTFT de 133724.2 ms) y la menor huella fisica (2.8 GB VRAM, 0.460 kWh). No obstante, al obtener 64.8% de precision (por debajo del umbral del 70.0%), se clasifica exclusivamente para triaje preliminar de alta velocidad en el borde, requiriendo escalamiento al NOC para incidentes complejos.

Reporte autogenerado por NetDiagBench-L7 (selecci■■n de modelos del usuario).

Parte II: Análisis Correlacional y Significancia Estadística

Analisis Correlacional y de Significancia Estadistica

Modulo: NetDiagBench-L7 / Layer 7 - Statistical Analysis

Muestras totales: 162 corridas, 3 modelos evaluados

---

1. Correlacion Parametros del Modelo vs Metricas de Rendimiento

Analisis de la relacion entre el numero de parametros del modelo (eje X)

y cada metrica de rendimiento (eje Y), usando correlacion de Spearman (rho)

y Pearson (r) con su p-value asociado.

Metrica	Spearman rho	p-value	Pearson r	p-value	Significativo (p<0.05)
TTFT (ms)	0.8119	p < 0.001	0.8801	p < 0.001	Si
Tokens/s	-0.3963	p < 0.001	-0.569	p < 0.001	Si
Latencia Total (ms)	0.5039	p < 0.001	0.5886	p < 0.001	Si
Energia (kWh)	0.5044	p < 0.001	0.5874	p < 0.001	Si
Rubrica (0-5)	0.2864	p < 0.001	0.3113	p < 0.001	Si
Puntaje de Coincidencia Parcial	0.2934	p < 0.001	0.2961	p < 0.001	Si

2. Prueba de Kruskal-Wallis: Diferencias entre Modelos

H0: Las distribuciones de la metrica son identicas entre los k modelos.

Se rechaza H0 si p < 0.05.

Metrica	H Estadistico	p-value	Diferencias Significativas
TTFT (ms)	114.4049	p < 0.001	Si
Tokens/s	132.6446	p < 0.001	Si
Latencia Total (ms)	133.9315	p < 0.001	Si
Energia (kWh)	133.8047	p < 0.001	Si
Rubrica (0-5)	15.3527	p < 0.001	Si
Puntaje de Coincidencia Parcial	15.2939	p < 0.001	Si

3. Intervalos de Confianza Bootstrap al 95%

Modelo	Metrica	IC 95% Inferior	IC 95% Superior
glm-4-9b-chat	TTFT (ms)	276742.8644	299240.8004
glm-4-9b-chat	Tokens/s	2.8839	2.938
glm-4-9b-chat	Latencia (ms)	486855.9228	544906.4981
glm-4-9b-chat	Energia (kWh)	0.0197	0.0221
phi-4-mini-instruct	TTFT (ms)	129529.0069	137507.3656
phi-4-mini-instruct	Tokens/s	3.2385	3.3426
phi-4-mini-instruct	Latencia (ms)	203372.0052	216673.8213
phi-4-mini-instruct	Energia (kWh)	0.0082	0.0088
qwen3-8b	TTFT (ms)	243315.5806	263356.8913
qwen3-8b	Tokens/s	1.7196	1.7822
qwen3-8b	Latencia (ms)	840660.5244	1025573.2961
qwen3-8b	Energia (kWh)	0.0341	0.0416

4. Tamano del Efecto (d de Cohen) entre Pares de Modelos

Metrica	Comparacion	d de Cohen	Interpretacion
TTFT (ms)	glm-4-9b-chat vs phi-4-mini-instruct	4.6611	Efecto grande (Large)
TTFT (ms)	glm-4-9b-chat vs qwen3-8b	0.8214	Efecto grande (Large)
TTFT (ms)	phi-4-mini-instruct vs qwen3-8b	-3.9367	Efecto grande (Large)
Tokens/s	glm-4-9b-chat vs phi-4-mini-instruct	-2.4651	Efecto grande (Large)
Tokens/s	glm-4-9b-chat vs qwen3-8b	10.5403	Efecto grande (Large)
Tokens/s	phi-4-mini-instruct vs qwen3-8b	9.6435	Efecto grande (Large)
Latencia Total (ms)	glm-4-9b-chat vs phi-4-mini-instruct	3.9943	Efecto grande (Large)
Latencia Total (ms)	glm-4-9b-chat vs qwen3-8b	-1.5455	Efecto grande (Large)
Latencia Total (ms)	phi-4-mini-instruct vs qwen3-8b	-2.7993	Efecto grande (Large)

5. Estadisticos Descriptivos Consolidados por Modelo

Modelo	Metrica	Media	Sigma	CV%	p50	p95	N
glm-4-9b-chat	TTFT (ms)	288148.8176	44173.7564	15.33	295931.7	372773.78	54
glm-4-9b-chat	Tokens/s	2.9102	0.1034	3.55	2.93	3.03	54
glm-4-9b-chat	Latencia (ms)	516344.7539	105628.2208	20.46	501916.83	706684.77	54
glm-4-9b-chat	VRAM (Declarada/Estimada) Pico (GB)	5.9	0.0	0.0	5.9	5.9	54
glm-4-9b-chat	RAM Pico (MB)	92.0196	25.4892	27.7	85.77	128.25	54
glm-4-9b-chat	Energia (kWh)	0.021	0.0043	20.45	0.0203	0.0287	54
glm-4-9b-chat	Rubrica (0-5)	4.1296	0.8079	19.56	4.0	5.0	54
glm-4-9b-chat	Puntaje de Coincidencia Parcial	0.6073	0.3117	51.32	0.66	1.0	54
phi-4-mini-instruct	TTFT (ms)	133724.1556	15618.2668	11.68	136320.47	150892.34	54
phi-4-mini-instruct	Tokens/s	3.2931	0.1939	5.89	3.34	3.52	54
phi-4-mini-instruct	Latencia (ms)	210324.9913	24123.7065	11.47	213264.28	248464.14	54
phi-4-mini-instruct	VRAM (Declarada/Estimada) Pico (GB)	2.8	0.0	0.0	2.8	2.8	54
phi-4-mini-instruct	RAM Pico (MB)	83.4776	11.7526	14.08	82.3	111.76	54
phi-4-mini-instruct	Energia (kWh)	0.0085	0.001	11.5	0.0085	0.0102	54
phi-4-mini-instruct	Rubrica (0-5)	3.5463	0.8969	25.29	4.0	5.0	54
phi-4-mini-instruct	Puntaje de Coincidencia Parcial	0.3603	0.3428	95.15	0.2	1.0	54
qwen3-8b	TTFT (ms)	253500.0587	40092.897	15.82	261629.54	328665.68	54
qwen3-8b	Tokens/s	1.7533	0.1158	6.6	1.78	1.88	54
qwen3-8b	Latencia (ms)	928438.7435	361994.758	38.99	761328.4	1681854.98	54
qwen3-8b	VRAM (Declarada/Estimada) Pico (GB)	5.5	0.0	0.0	5.5	5.5	54
qwen3-8b	RAM Pico (MB)	90.2759	9.6803	10.72	90.24	105.7	54
qwen3-8b	Energia (kWh)	0.0377	0.0148	39.37	0.0304	0.0689	54
qwen3-8b	Rubrica (0-5)	4.0741	0.7098	17.42	4.0	5.0	54
qwen3-8b	Puntaje de Coincidencia Parcial	0.5435	0.3596	66.17	0.5	1.0	54

6. M■®tricas de Clasificaci■■n Diagn■■stica y F1 Macro (Tarea 4.1.3)

Modelo	F1 Macro	IC 95% Bootstrap F1	Precisi■■n Macro	Recall Macro
glm-4-9b-chat	0.7569	[0.5622, 0.8708]	0.8426	0.7407
phi-4-mini-instruct	0.6615	[0.4952, 0.7462]	0.7972	0.6111
qwen3-8b	0.8480	[0.6420, 0.9679]	0.8611	0.8704

7. Interpretacion y Conclusiones (Tarea 4.1.2 / OE4)

Se encontraron correlaciones estadisticamente significativas ($p < 0.05$) entre el numero de parametros del modelo y las siguientes metricas: **TTFT (ms), Tokens/s, Latencia Total (ms), Energia (kWh), Rubrica (0-5), Puntaje de Coincidencia Parcial**.

La prueba de Kruskal-Wallis revela diferencias estadisticamente significativas entre modelos en: **TTFT (ms), Tokens/s, Latencia Total (ms), Energia (kWh), Rubrica (0-5), Puntaje de Coincidencia Parcial** ($p < 0.05$), lo que confirma que la eleccion del modelo tiene un impacto medible en el rendimiento.

Reporte autogenerado por NetDiagBench-L7 Statistical Analysis Module.