NetDiagBench-L7: Informe Técnico Consolidado

Universidad de Pamplona · Evaluación Integral de Modelos SLM para Diagnóstico L7

Informe Técnico Comparativo: NetDiagBench-L7

Fecha de Generación: 2026-11-06 14:12:14

Huella de Hardware: `OS=Windows_11; CPU=AMD64 Family 23 Model 160 Stepping 0, AuthenticAMD; Cores=8; RAM=13.83GB; GPU=AMD Radeon(TM) 610M; VRAM=2.0GB`

Total de Pruebas Incluidas: 162

Modelos Incluidos en el Informe: glm-4-9b-chat, phi-4-mini-instruct, qwen3-8b

1. Matriz de Evaluación Multidimensional (OE4 / Tarea 4.2.2)

Modelo	Precisión Diagnóstica	Puntaje de Coincidencia Parcial	Tasa Evidencia	TTFT Prom.	Vel. Tok/s	Latencia p50	Latencia p95	VRAM (Declarada/Estimada) Pico	Rúbrica (0-5)
glm-4-9b-chat	88.9%	0.761	96.3%	182836.0 ms	3.4 tok/s	379153.6 ms	609063.1 ms	5.9 GB	4.13 / 5.0
phi-4-mini-instruct	59.3%	0.496	90.7%	83215.4 ms	5.1 tok/s	173283.5 ms	264736.0 ms	2.84 GB	3.55 / 5.0
qwen3-8b	85.2%	0.736	96.3%	161507.9 ms	3.5 tok/s	353103.5 ms	637374.2 ms	5.5 GB	4.07 / 5.0

2. Desglose de Precisión por Escenario y Modelo

Escenario	glm-4-9b-chat	phi-4-mini-instruct	qwen3-8b
DNS-DEL-01	[OK] 100%	[!] 67%	[OK] 100%
DNS-NXD-01	[OK] 100%	[OK] 100%	[OK] 100%
DNS-REF-01	[OK] 100%	[OK] 100%	[OK] 100%
DNS-SRV-01	[!] 67%	[!] 0%	[OK] 100%
DNS-TRUNC-01	[OK] 100%	[OK] 100%	[OK] 100%
HTTP-403-01	[OK] 100%	[!] 33%	[OK] 100%
HTTP-429-01	[OK] 100%	[OK] 100%	[OK] 100%
HTTP-500-01	[OK] 100%	[OK] 100%	[OK] 100%
HTTP-502-01	[OK] 100%	[!] 0%	[OK] 100%
HTTP-503-01	[!] 67%	[!] 33%	[!] 33%
HTTP-504-01	[!] 67%	[!] 67%	[OK] 100%
HTTP-ORIGIN-01	[OK] 100%	[!] 33%	[!] 67%
HTTP-POOL-01	[OK] 100%	[!] 67%	[OK] 100%
NET-LAT-01	[!] 33%	[!] 0%	[!] 33%
TLS-CHN-01	[OK] 100%	[OK] 100%	[OK] 100%
TLS-CIPH-01	[OK] 100%	[OK] 100%	[OK] 100%
TLS-EXP-01	[!] 67%	[!] 0%	[!] 0%
TLS-SNI-01	[OK] 100%	[!] 67%	[OK] 100%

3. Estimación de Huella Energética y Carbono (Tarea 4.2.2c)

Modelo	Energía Total (kWh)	CO2 Estimado (kg)	Eficiencia Tok/Wh
glm-4-9b-chat	0.911148 kWh	0.255121 kg	79189.3 tok/Wh
phi-4-mini-instruct	0.326502 kWh	0.091421 kg	124839.6 tok/Wh
qwen3-8b	0.862270 kWh	0.241436 kg	82263.8 tok/Wh

4. Análisis de Compromiso y Configuración Recomendada (Tarea 4.3.1)

Comparación de Compensaciones (Trade-Offs):

- **glm-4-9b-chat (9.0B):** Precision 88.9%, TTFT 182836.0 ms, 3.4 tok/s, VRAM 5.9 GB, Rubrica 4.13/5.0. Score de Eficiencia: **0.7504**.

Perfil: Especializacion robusta en seguimiento de esquemas estructurados de herramientas y contexto ultra-largo. Lidera con 88.9% de precision diagnostica, 4.41/5.0 en rubrica y score de compromiso multicriterio de 0.860.

- **qwen3-8b (8.2B):** Precision 85.2%, TTFT 161507.9 ms, 3.5 tok/s, VRAM 5.5 GB, Rubrica 4.07/5.0. Score de Eficiencia: **0.7442**.

Perfil: Equilibrio optimo entre capacidad de razonamiento nativo (<thought>), profundidad analitica y fidelidad en aislamiento de componentes (74.1%). Mayor calidad explicativa (4.48/5.0). Opera con margen holgado en GPUs de 8 GB VRAM (5.5 GB) y score de 0.850.

- **phi-4-mini-instruct (3.8B):** Precision 59.3%, TTFT 83215.4 ms, 5.1 tok/s, VRAM 2.84 GB, Rubrica 3.55/5.0. Score de Eficiencia: **0.7792**.

Perfil: Maxima eficiencia computacional y minima huella de VRAM (2.8 GB, TTFT de 82.2 ms, 4.5 tok/s, 0.328 kWh). Exactitud del 63.0% (sub-umbral autonomo del 70.0%), orientada a triaje preliminar de alta velocidad en estaciones de borde.

5. Desglose de Resultados por Modo de Ejecución (135 Simuladas vs. 27 Emuladas)

Modo de Ejecución	Total Corridas	Precisión Diagnóstica	Tasa Evidencia	Latencia Media (ms)	Rúbrica Prom.
Laboratorio en Contenedores (Docker Compose) (emulado)	27	48.1%	96.3%	460288.9 ms	3.78 / 5.0
Simulador Sintético Calibrado (sintetico _determinista)	135	83.7%	94.1%	294543.9 ms	3.94 / 5.0

Conclusion de Seleccion (OE4 / Tarea 4.3.1): 1. **Configuracion de Mejor Compromiso Global (NOC / Ingenieria de Red):** Tras filtrar por el umbral de exactitud viable (>= 70.0%), el modelo glm-4-9b-chat se posiciona como la configuracion de mejor compromiso global (Score de Compromiso: 0.750), alcanzando la maxima precision diagnostica (88.9%), 3.4 tok/s y una rubrica explicativa de 4.13/5.0 (VRAM declarada: 5.9 GB). 2. **Configuracion de Razonamiento CoT y Recursos Acotados:** Entre los modelos que superan el umbral de exactitud viable (70.0%), qwen3-8b presenta la menor huella computacional con 5.5 GB de VRAM (Declarada/Estimada), el mayor aislamiento de componentes (33.3%) y la mas alta calidad explicativa (rubrica 4.07/5.0 con 85.2% de precision), configurandose como la opcion recomendada para despliegues con recursos de GPU acotados (8 GB). 3. **Evaluacion para Despliegues de Borde y Triaje Preliminar (Edge Computing):** El modelo phi-4-mini-instruct ofrece la mayor velocidad (5.1 tok/s, TTFT de 83215.4 ms) y la menor huella fisica (2.84 GB VRAM, 0.327 kWh). No obstante, al obtener 59.3% de precision (por debajo del umbral del 70.0%), se clasifica exclusivamente para triaje preliminar de alta velocidad en el borde, requiriendo escalamiento al NOC para incidentes complejos.

Reporte autogenerado por NetDiagBench-L7 (selección de modelos del usuario).

Parte II: Análisis Correlacional y Significancia Estadística

Analisis Correlacional y de Significancia Estadistica

Modulo: NetDiagBench-L7 / Layer 7 - Statistical Analysis

Muestras totales: 162 corridas, 3 modelos evaluados

1. Correlacion Parametros del Modelo vs Metricas de Rendimiento

Analisis de la relacion entre el numero de parametros del modelo (eje X)

y cada metrica de rendimiento (eje Y), usando correlacion de Spearman (rho)

y Pearson (r) con su p-value asociado.

Metrica	Spearman rho	p-value	Pearson r	p-value	Significativo (p<0.05)
TTFT (ms)	0.8306	p < 0.001	0.7761	p < 0.001	Si
Tokens/s	-0.5884	p < 0.001	-0.2707	p < 0.001	Si
Latencia Total (ms)	0.7661	p < 0.001	0.8001	p < 0.001	Si
Energia (kWh)	0.7816	p < 0.001	0.8128	p < 0.001	Si
Rubrica (0-5)	0.2864	p < 0.001	0.3113	p < 0.001	Si
Puntaje de Coincidencia Parcial	0.3546	p < 0.001	0.4089	p < 0.001	Si

2. Prueba de Kruskal-Wallis: Diferencias entre Modelos

H0: Las distribuciones de la metrica son identicas entre los k modelos.

Se rechaza H0 si p < 0.05.

Metrica	H Estadistico	p-value	Diferencias Significativas
TTFT (ms)	115.9343	p < 0.001	Si
Tokens/s	58.0983	p < 0.001	Si
Latencia Total (ms)	109.5798	p < 0.001	Si
Energia (kWh)	110.9144	p < 0.001	Si
Rubrica (0-5)	15.3527	p < 0.001	Si
Puntaje de Coincidencia Parcial	26.2864	p < 0.001	Si

3. Intervalos de Confianza Bootstrap al 95%

Modelo	Metrica	IC 95% Inferior	IC 95% Superior
glm-4-9b-chat	TTFT (ms)	173733.825	193533.5359
glm-4-9b-chat	Tokens/s	3.2819	3.4226
glm-4-9b-chat	Latencia (ms)	383535.7183	427132.5596
glm-4-9b-chat	Energia (kWh)	0.0159	0.018
phi-4-mini-instruct	TTFT (ms)	76912.9794	89507.4619
phi-4-mini-instruct	Tokens/s	4.292	6.538
phi-4-mini-instruct	Latencia (ms)	161787.5457	186661.4344
phi-4-mini-instruct	Energia (kWh)	0.0056	0.0065
qwen3-8b	TTFT (ms)	151745.6528	173262.8374
qwen3-8b	Tokens/s	3.3343	3.6367
qwen3-8b	Latencia (ms)	363856.3128	417268.8717
qwen3-8b	Energia (kWh)	0.0149	0.0173

4. Tamano del Efecto (d de Cohen) entre Pares de Modelos

Metrica	Comparacion	d de Cohen	Interpretacion
TTFT (ms)	glm-4-9b-chat vs phi-4-mini-instruct	3.1227	Efecto grande (Large)
TTFT (ms)	glm-4-9b-chat vs qwen3-8b	0.5406	Efecto mediano (Medium)
TTFT (ms)	phi-4-mini-instruct vs qwen3-8b	-2.3692	Efecto grande (Large)
Tokens/s	glm-4-9b-chat vs phi-4-mini-instruct	-0.5054	Efecto mediano (Medium)
Tokens/s	glm-4-9b-chat vs qwen3-8b	-0.2908	Efecto pequeno (Small)
Tokens/s	phi-4-mini-instruct vs qwen3-8b	0.4647	Efecto pequeno (Small)
Latencia Total (ms)	glm-4-9b-chat vs phi-4-mini-instruct	3.438	Efecto grande (Large)
Latencia Total (ms)	glm-4-9b-chat vs qwen3-8b	0.167	Efecto insignificante (Negligible)
Latencia Total (ms)	phi-4-mini-instruct vs qwen3-8b	-2.8173	Efecto grande (Large)

5. Estadisticos Descriptivos Consolidados por Modelo

Modelo	Metrica	Media	Sigma	CV%	p50	p95	N
glm-4-9b-chat	TTFT (ms)	182835.9909	38502.7137	21.06	169766.42	279890.69	54
glm-4-9b-chat	Tokens/s	3.3576	0.2689	8.01	3.48	3.56	54
glm-4-9b-chat	Latencia (ms)	403622.2928	83070.8367	20.58	379153.58	609063.12	54
glm-4-9b-chat	VRAM (Declarada/Estimada) Pico (GB)	5.9	0.0	0.0	5.9	5.9	54
glm-4-9b-chat	RAM Pico (MB)	392.1669	159.6219	40.7	420.77	581.06	54
glm-4-9b-chat	Energia (kWh)	0.0169	0.0039	22.91	0.0159	0.0265	54
glm-4-9b-chat	Rubrica (0-5)	4.1296	0.8079	19.56	4.0	5.0	54
glm-4-9b-chat	Puntaje de Coincidencia Parcial	0.7615	0.2076	27.26	0.8	1.0	54
phi-4-mini-instruct	TTFT (ms)	83215.3641	23517.1987	28.26	77004.29	128316.29	54
phi-4-mini-instruct	Tokens/s	5.108	4.8907	95.75	4.77	5.12	54
phi-4-mini-instruct	Latencia (ms)	174412.4165	44599.089	25.57	173283.46	264736.02	54
phi-4-mini-instruct	VRAM (Declarada/Estimada) Pico (GB)	2.8407	0.2994	10.54	2.8	2.8	54
phi-4-mini-instruct	RAM Pico (MB)	223.6072	108.0076	48.3	223.19	389.18	54
phi-4-mini-instruct	Energia (kWh)	0.006	0.0017	27.71	0.0058	0.0096	54
phi-4-mini-instruct	Rubrica (0-5)	3.5463	0.8969	25.29	4.0	5.0	54
phi-4-mini-instruct	Puntaje de Coincidencia Parcial	0.4957	0.3334	67.26	0.6176	0.9608	54
qwen3-8b	TTFT (ms)	161507.9446	40385.8496	25.01	143054.61	249486.27	54
qwen3-8b	Tokens/s	3.4896	0.583	16.71	3.82	4.02	54
qwen3-8b	Latencia (ms)	388469.5481	97756.8374	25.16	353103.49	637374.21	54
qwen3-8b	VRAM (Declarada/Estimada) Pico (GB)	5.5	0.0	0.0	5.5	5.5	54
qwen3-8b	RAM Pico (MB)	157.6437	40.1918	25.5	145.91	240.34	54
qwen3-8b	Energia (kWh)	0.016	0.0044	27.65	0.0144	0.0272	54
qwen3-8b	Rubrica (0-5)	4.0741	0.7098	17.42	4.0	5.0	54
qwen3-8b	Puntaje de Coincidencia Parcial	0.736	0.2513	34.15	0.8	1.0	54

6. Métricas de Clasificación Diagnóstica y F1 Macro (Tarea 4.1.3)

Modelo	F1 Macro	IC 95% Bootstrap F1	Precisión Macro	Recall Macro
glm-4-9b-chat	0.8832	[0.7092, 0.9333]	0.9130	0.8889
phi-4-mini-instruct	0.5529	[0.4033, 0.6100]	0.5741	0.5926
qwen3-8b	0.8302	[0.6741, 0.8806]	0.8444	0.8519

7. Interpretacion y Conclusiones (Tarea 4.1.2 / OE4)

Se encontraron correlaciones estadisticamente significativas ($p < 0.05$) entre el numero de parametros del modelo y las siguientes metricas: **TTFT (ms), Tokens/s, Latencia Total (ms), Energia (kWh), Rubrica (0-5), Puntaje de Coincidencia Parcial**.

La prueba de Kruskal-Wallis revela diferencias estadisticamente significativas entre modelos en: **TTFT (ms), Tokens/s, Latencia Total (ms), Energia (kWh), Rubrica (0-5), Puntaje de Coincidencia Parcial** ($p < 0.05$), lo que confirma que la eleccion del modelo tiene un impacto medible en el rendimiento.

Reporte autogenerado por NetDiagBench-L7 Statistical Analysis Module.