UNIVERSIDAD DE PAMPLONA
FACULTAD DE INGENIERÍAS Y ARQUITECTURA
DEPARTAMENTO E.E.S.T. — INGENIERÍA DE TELECOMUNICACIONES

MANUAL DE USUARIO Y GUÍA OPERATIVA

Operación del Dashboard Interactivo, Diagnóstico en Streaming en Vivo, Gestión de Modelos y Análisis Comparativo con Pantallazos Reales

Proyecto de Grado: Benchmark Reproducible para Diagnóstico de Fallas L7 con SLMs Locales

Autor: Juan David León Arrieta (juan.leon22@unipamplona.edu.co)
Director: Mg. Richard Eliseo Mendoza Gáfaro (richard.mendoza@unipamplona.edu.co)
Versión del Software: v1.0.0 • **Fecha:** Noviembre 2026
Arquitectura: 7 Capas Desacopladas • RAG BM25 (≤0.05 MB) • LangGraph Read-Only • Typer CLI + FastAPI/HTMX
Entorno de Ejecución: 100% Local • 8 GB VRAM • Ollama / llama.cpp (GGUF Q4_K_M)

1. Bienvenida y Requisitos del Entorno

Bienvenido a la **Guía de Usuario de NetDiagBench-L7**. Esta aplicación web y CLI permite a operadores de Centros de Operaciones de Red (NOC), administradores de sistemas e investigadores evaluar y operar asistentes inteligentes basados en Modelos de Lenguaje Pequeños (SLMs) locales para diagnosticar fallas en servicios de red L7 sobre IP en tiempo real.

Requisitos Recomendados de Hardware y Software:

- **Sistema Operativo:** Windows 11 / 10 (64-bit) o Linux Ubuntu 22.04+.
- **GPU Dedicada:** NVIDIA GeForce RTX con mínimo 8 GB de VRAM (CUDA ≥ 12.0) o procesador CPU de 8 núcleos para modo determinista.
- **Memoria RAM:** 32 GB RAM recomendados (16 GB mínimo para ejecución de modelos 8B/9B).
- **Almacenamiento:** 25 GB libres en disco de estado sólido (NVMe/SSD) para almacenar modelos GGUF y registros.
- **Software Requerido:** Python 3.11+, Ollama (opcional para inferencia en GPU en vivo) y navegador web moderno (Chrome / Edge / Firefox).

2. Inicio Rápido de la Aplicación

Para iniciar el sistema de diagnóstico interactivo existen dos métodos directos:

Opción A: Lanzador rápido PowerShell (Demostración y Sustentación):

```
# En la raíz del proyecto, ejecute el script oficial de lanzamiento:
powershell -ExecutionPolicy Bypass -File scripts\launch_demo.ps1
```

Opción B: Arranque manual mediante la CLI:

```
# 1. Activar el entorno virtual
.\.venv\Scripts\Activate.ps1

# 2. Iniciar el servidor web interactivo FastAPI
benchapp serve-dashboard --host 127.0.0.1 --port 8000

# 3. Abra su navegador en: http://localhost:8000
```

3. Recorrido General por la Interfaz Web

La interfaz del sistema está construida con arquitectura **Local-First** utilizando Tailwind CSS, HTMX para interactividad reactiva sin recarga de página, Alpine.js para control modal y Server-Sent Events (SSE) para transmitir la telemetría en streaming mientras el agente SLM razona y diagnostica.

Figura 1: Pantalla principal de NetDiagBench-L7 mostrando el Visor de Diagnóstico, barra lateral de navegación y panel de configuración inicial. *(Captura del aplicativo disponible en el dashboard web)*

La interfaz se estructura en cuatro cuadrantes principales:

1. **Barra de Navegación Lateral (Izquierda):** Permite conmutar instantáneamente entre las 5 vistas maestras: Visor de Diagnóstico (1), Informe Comparativo OE4 (2), Análisis Correlacional SciPy (3), Informe Consolidado HTML (4) y Suite de Observabilidad (5).
2. **Panel de Ground Truth y Bitácora (Lateral Inferior):** Presenta los datos de verdad terreno del escenario activo y el historial en memoria de los diagnósticos previos.
3. **Barra Superior (Header):** Muestra la insignia de ejecución 100% Local, el estado de conectividad en vivo con Ollama (latencia ping en milisegundos y modelos cargados), monitor de VRAM y botón de cambio de tema visual.
4. **Espacio de Trabajo Central (Workspace):** Área reactiva donde se configuran los parámetros de prueba y se renderiza el streaming en tiempo real.

4. Barra Superior y Monitor de Recursos

Figura 2: Encabezado institucional con estado de Ollama Live, latencia de ping, conteo de modelos locales y huella de VRAM cuantizada (Q4_K_M). ***(Captura del aplicativo disponible en el dashboard web)***

La barra superior garantiza que el jurado evaluador o el operador verifiquen en todo momento que el sistema no depende de internet externo y que la GPU opera dentro del límite de 8 GB VRAM. El badge verde **OLLAMA LIVE** pulsa activamente mientras el motor de inferencia responde a las peticiones locales.

5. Selección y Filtrado Rápido de Escenarios

El operador puede filtrar rápidamente los 18 escenarios de red por su tecnología específica utilizando las píldoras de filtro: **Todos**, **DNS**, **TLS**, **HTTP** y **GW** (API Gateway).

Figura 3: Filtro por categoría 'TLS' seleccionando el escenario TLS-EXP-01 con carga automática de la ficha técnica. ***(Captura del aplicativo disponible en el dashboard web)***

6. Ficha Técnica de Ground Truth (Verdad Terreno)

Figura 4: Ficha lateral de Ground Truth detallando la causa raíz esperada, componente afectado y el Procedimiento Operativo Estándar (SOP). ***(Captura del aplicativo disponible en el dashboard web)***

Al seleccionar un escenario, la ficha lateral izquierda se actualiza automáticamente indicando el diagnóstico de referencia establecido por el laboratorio. Esto permite contrastar visualmente la predicción del modelo con la verdad técnica inyectada en el tráfico de red.

7. Paleta de Comandos de Acceso Rápido (Ctrl + K)

Para operadores avanzados, la aplicación incorpora una paleta de comandos tipo terminal accesible mediante la combinación de teclas Ctrl + K o haciendo clic en el buscador superior:

Figura 5: Paleta de comandos modal rápida para navegación entre vistas, ejecución de diagnósticos y alternancia de temas. ***(Captura del aplicativo disponible en el dashboard web)***

8. Gestor Interactivo de Modelos SLM (Ollama Hub)

Haciendo clic en el botón **+ Añadir nuevo modelo** en la barra de configuración, se despliega un catálogo categorizado de modelos ligeros disponibles para ser descargados directamente en local:

Figura 6: Gestor de modelos SLM locales organizado por categorías: Ultraligeros (≤2B), Razonamiento CoT (DeepSeek-R1), Intermedios (3B-4B), Código y Capacidad Completa (7B-9B). ***(Captura del aplicativo disponible en el dashboard web)***

El usuario puede pulsar sobre cualquier etiqueta (por ejemplo phi4-mini:instruct o qwen2.5:1.5b) para iniciar la descarga con barra de progreso en vivo vía Server-Sent Events, o ingresar una etiqueta personalizada.

9. Soporte para Modo Claro / Diurno

Figura 7: Visualización del sistema en Tema Claro con alto contraste y paleta institucional (Rojo Pamplona #ad3333 y Azul Marino #003366). ***(Captura del aplicativo disponible en el dashboard web)***

10. Ejecución del Diagnóstico y Streaming en Vivo

Para ejecutar un diagnóstico interactivo, seleccione el escenario deseado (ej. DNS-NXD-01), el modelo de lenguaje (ej. Phi-4-mini-instruct), la semilla determinista (42) y presione el botón rojo **Ejecutar Diagnóstico (CTRL + ↵)**.

Figura 8: Terminal de Observabilidad en streaming mostrando el Stepper de 5 fases activas y la ingesta de telemetría y RAG en tiempo real. ***(Captura del aplicativo disponible en el dashboard web)***

Durante el procesamiento, el Stepper superior ilustra el avance por las 5 etapas del agente LangGraph: **1. TELEMETRÍA** (Drain3 PCAP) → **2. RAG IETF** (Normas RFC) → **3. RAZONAMIENTO** (CoT Hipótesis) → **4. CONSOLA CLI** (Read-Only Tool) → **5. VEREDICTO** (Causa & Mitigación).

11. Verificación de Evidencia en Terminal Read-Only

Figura 9: Consola de evidencia donde el agente SLM ejecuta herramientas de red de solo lectura (dig @127.0.0.1 A) para comprobar su hipótesis. ***(Captura del aplicativo disponible en el dashboard web)***

El operador puede inspeccionar la caja de terminal verde tipo bash donde se aprecia el comando exacto invocado por el modelo (dig @127.0.0.1 -p 5353 app.internal.corp A) y la respuesta del servidor BIND9 (status: NXDOMAIN), garantizando total auditabilidad.

12. Veredicto Final, Confianza y Mitigación NOC

Figura 10: Tarjeta de Veredicto Final con causa raíz sintetizada, componente culpable, acción correctiva SOP, fundamentación técnica y nivel de confianza. ***(Captura del aplicativo disponible en el dashboard web)***

Una vez concluido el ciclo, el sistema genera la tarjeta formal de diagnóstico destacando:

- **Causa Raíz Identificada:** Explicación concisa del origen del fallo.
- **Componente Afectado:** Elemento de red o microservicio específico que debe ser intervenido.
- **Acción Sugerida (SOP):** Procedimiento operativo recomendado para restaurar el servicio.
- **Botón 'Copiar Ficha para Ticket':** Permite copiar al portapapeles el dictamen en formato Markdown para abrir un ticket de soporte en Jira o ServiceNow.

13. Bitácora de Sesión en Memoria RAM

Figura 11: Bitácora de sesión interactiva registrando diagnósticos previos, aciertos, fallas y uso de memoria LangGraph MemorySaver. ***(Captura del aplicativo disponible en el dashboard web)***

La bitácora lateral almacena las ejecuciones recientes de la sesión. Permite al usuario hacer clic en cualquier diagnóstico histórico para recargar instantáneamente su traza completa sin reejecutar la inferencia.

14. Informe Técnico Comparativo Multidimensional (OE4)

Al seleccionar la pestaña **Informe Comparativo (OE4)** en el menú lateral, se presenta el análisis consolidado de las 162 corridas experimentales evaluando los 3 modelos de la terna:

Figura 12: Informe Comparativo Multidimensional (OE4) con tarjetas de perfil de modelo, scores de compromiso compuesto (0.860 vs 0.850 vs 0.746) y métricas de trade-off. ***(Captura del aplicativo disponible en el dashboard web)***

La vista clasifica a los modelos según su caso de uso óptimo en infraestructura:

- **GLM-4-9B-Chat (Score 0.860):** *Recomendado para Centro de Operaciones (NOC)* por su precisión superior (88.9%), soporte de contexto de 128k y robustez en seguimiento de herramientas.
- **Qwen3-8B (Score 0.850):** *Recomendado para Recursos Acotados* por su equilibrio en razonamiento CoT (<thought>), alta fidelidad en componentes (74.1%) y 4.48/5.0 en rúbrica.
- **Phi-4-mini-instruct (Score 0.746):** *Orientado a Triaje de Borde (Edge Triage)* por su mínima huella de VRAM (2.8 GB), bajísimo TTFT (84.4 ms) y alta velocidad (4.5 tok/s).

15. Análisis Correlacional y Significancia Estadística

Figura 13: Vista de Análisis Correlacional (Tarea 4.1.2) con pruebas Kruskal-Wallis, coeficientes de Spearman/Pearson, intervalos de confianza 95% y tamaños de efecto d de Cohen. ***(Captura del aplicativo disponible en el dashboard web)***

Esta sección valida científicamente ante el jurado que las diferencias observadas no se deben al azar. Las 6 pruebas de Kruskal-Wallis rechazan la hipótesis nula ($p < 0.001$) para TTFT, tokens/s, latencia y energía, confirmando que el tamaño del modelo tiene un impacto significativo en los recursos computacionales consumidos.

16. Suite de Observabilidad Continua (18 Escenarios)

Figura 14: Suite de Observabilidad completa para la ejecución secuencial desatendida de los 18 escenarios catalogados. ***(Captura del aplicativo disponible en el dashboard web)***

La Suite de Observabilidad permite poner a prueba la batería completa de 18 escenarios de forma secuencial y determinista. El operador puede iniciar o detener la prueba con un solo clic, visualizando el avance acumulado y exportando al finalizar el reporte integral en PDF o Excel.

17. Barra de Herramientas de Exportación

En la esquina superior derecha de cada vista se encuentra la barra flotante de exportación, la cual permite descargar los resultados en múltiples formatos estándar de la industria:

- **Descargar Excel (.xlsx):** Genera el libro multioja con tablas dinámicas de resultados, comparativas y análisis correlacional.
- **Exportar Reporte PDF:** Descarga el documento formal en PDF listo para impresión o anexar al trabajo de grado.
- **Descargar CSV / JSON:** Permite a investigadores cargar las 162 filas de datos en Python (Pandas), R o MATLAB.
- **Botón de Imprimir:** Formatea la vista web para impresión limpia o guardado directo a PDF del navegador.

18. Preguntas Frecuentes y Solución de Problemas (FAQ)

P: ¿Qué hacer si Ollama muestra estado desconectado (badge rojo)?
R: El sistema activa automáticamente el *Simulador Sintético Calibrado* de alta fidelidad, permitiendo la demostración completa sin interrupciones. Para levantar Ollama, abra una terminal y ejecute ollama serve.

P: ¿Cómo verificar que no se sobrepasan los 8 GB de VRAM?
R: El monitor superior y el comando benchapp doctor auditan el consumo de VRAM en tiempo real. Ningún modelo de la terna supera los 5.9 GB de VRAM en su cuantización Q4_K_M.

P: ¿Dónde se guardan los reportes y diagnósticos exportados?
R: Todos los artefactos se depositan de manera determinista en el directorio data/benchmark_results/ y los registros individuales en data/runs/.